

Parcial 1 ingeniería de datos

Grupo 2

Nombre: JJJA

Jhonatan Gutierrez Rondon:

https://github.com/kajirre/Ingenieria_Datos/tree/main/primer_corte/parcial_practico_31_agosto/parcial_practico

Jorge Reza:

<https://github.com/Jorge-Reza/Ingenieria-de-datos-/tree/main/Primer%20corte/Pracial%20practico-%20momento%205>

Juan Camacho:

Amelia Joya:

<https://github.com/AJT06/IngenieriadeDatos2026-2S/tree/957f8c3a36b15f4b7d70a49a00a7266fdd8b03a1/Parcial%20pr%C3%A1ctico%201>

Momento 1

Momento 1 · Sala de servidores

10 minutos | Corredor 1 | 15 puntos | Insumo: M1_inventario_fuentes.csv

Entraste a la sala de servidores de VeloBog y encontraste tres tableros desordenados. Para abrir la puerta del siguiente cuarto hay que resolverlos.

1.1 Ordena el flujo · 4 puntos

Numera de 1 a 7 según el ciclo de vida del dato:

Etapas	N°	Etapas	N°
Visualización y consumo	7	Modelado y análisis	6
Almacenamiento en el data warehouse	3	Generación del dato en el origen	1
Ingesta desde las fuentes	4	Transformación y limpieza	2
Gobierno y monitoreo continuo	5		

1.2 Empareja el rol con la frase · 4 puntos

Rol	Letra + número	Frase que diría en una reunión
A. Ingeniero de datos	2	1. «Necesito que el reporte de ocupación esté listo cada lunes a las 7 a.m.»
B. Analista de datos	1	2. «El pipeline se cayó anoche, la partición del 14 no cargó.»
C. Científico de datos	3	3. «Voy a entrenar un modelo para predecir la demanda por estación.»
D. Stakeholder de negocio	4	4. «Con estos gráficos se ve que los martes cae el uso un 12 %.»

1.3 Verdadero o falso, con justificación de una línea · 4 puntos

Sin justificación la respuesta no puntúa.

Afirmación	V/F	Justificación
a. Un dato con formato correcto es automáticamente un dato de calidad.	F	Un dato puede no ser de calidad si su metodología para estudio es errónea.
b. El EDA se hace después de tener el modelo entrenado.	F	
c. En un pipeline ELT la transformación ocurre dentro del sistema de destino.	V	
d. Los requerimientos no funcionales son opcionales porque no describen funciones del sistema.	V	Los req no funcionales por lo general se apegan más a temas de conveniencia o eficiencia pues no son necesarios para las funciones básicas.

1.4 Reto de lógica · 3 puntos

Abre M1_inventario_fuentes.csv. Hay tres fuentes: App móvil, Candelados IoT y Excel de Operaciones. Dos celdas están marcadas con «?» y debes deducirlas con estas pistas:

- La fuente que actualiza en tiempo real no es la que tiene errores de digitación → Excel se maneja manual.

- La fuente con más registros duplicados es la que reintenta el envío cuando pierde señal. → *candados*.
- La app registra el inicio del viaje, pero no el final. → *No App*.

Pregunta: ¿cuál es la única fuente confiable para saber a qué hora terminó un viaje, y por qué esa misma fuente exige una deduplicación obligatoria en el pipeline? Responde en máximo tres renglones.

Entregable: hoja de respuestas del momento 1 con el nombre del corredor.

La única fuente confiable es Candados IoT puesto que un excel diligenciado manualmente siempre es susceptible a errores de digitación y la App no registra el final de un viaje por lo tanto es IoT por eliminación.

Momento 2

Momento 2 · Datos sucios

18 minutos | Corredor 2 | 25 puntos | Insumo: M2_viajes_agosto.csv (Anexo A)

El equipo de la app te pasó una muestra del archivo viajes_agosto.csv. La coordinadora jura que está limpio. No lo está.

2.1 Auditoría de calidad · 10 puntos

Revisa el Anexo A e identifica mínimo ocho problemas de calidad distintos. Para cada uno completa una fila:

#	Fila / columna	Problema detectado	Tipo	Regla de transformación propuesta
1	Columna J	Hay inconsistencia en la escritura de las palabras	Formato	Unificar el formato de las palabras. Normalizar formato.
2	4 / G	Hay un valor que se repite repetido. Los datos repetidos.	Valor atípico	Establecer un límite en los valores mínimos y máximos permitidos, y no dejar ningún número negativo.
3	Fila 8	No hay los registros en esa fila.	Nulo	Se puede eliminar la fila porque tiene muchos datos nulos.
4	3 / E	La fecha registrada está escrita en un formato distinto.	Formato	Unificar el formato a la de los otros.
5	Filas 9-10	Las 2 filas tienen exactamente los mismos registros.	Duplicado	Eliminar uno de los registros porque son exactamente iguales.
6	6-7 / I	Los valores no tienen sentido para ser la edad de un usuario.	Valores atípicos	Establecer límites de los rangos de edad permitidos y eliminar al usuario.
7	13 / H	El valor del costo no tiene sentido ya que no puede ser un valor negativo.	Valores atípicos	No permitir valores negativos estableciendo límites. Contar registros.
8	12 / G	El valor es muy diferente al resto de valores de la columna.	Inconsistencia	Establecer un rango y tener cuidado en esos casos específicos de Montevideo y de Uruguay. La ciudad no puede ser tanto, no tiene sentido.

Tipos válidos: duplicado · nulo · formato · inconsistencia · valor atípico · violación de regla de negocio.

Ojo: dos problemas del anexo no se ven mirando una sola celda. Se detectan comparando columnas entre sí.

2.2 Diseño del pipeline · 9 puntos

Escribe el pipeline en pseudocódigo o SQL, con las tres fases rotuladas:

- **[E] EXTRACT:** de dónde, con qué frecuencia y cómo detectas registros nuevos.
- **[T] TRANSFORM:** mínimo cinco operaciones, en el orden correcto.
- **[L] LOAD:** destino, granularidad (¿una fila por qué cosa?) y estrategia de carga.

Debes justificar por qué la deduplicación va antes o después de la conversión de tipos.

2.3 Decisión de ingeniería · 6 puntos

Responde y argumenta en máximo cuatro renglones cada una:

- a. Encontraste 47 viajes con duración negativa. Tienes tres opciones: eliminar, imputar o cuarentena. ¿Cuál eliges y cuál es el costo de las otras dos?
- b. El campo estación de origen viene escrito de seis formas distintas para la misma estación. ¿Lo resuelves con normalización de texto o con una tabla maestra de estaciones? Sustenta.

Entregable: tabla de auditoría más pipeline escrito.

2.2

La operación de transformar duplicados va antes de la conversión de tipos, ya que, si no se eliminan los duplicados, si hay errores, se van a transformar los mismos datos, la cantidad de veces que estén duplicados (en filas).

2.3

A. No los puedo eliminar porque son demasiados datos, y tampoco imputar nuevos porque ya hay registros en esas casillas, entonces se van a cuarentena, y se gestionan esos datos de manera diferente sin eliminarlos y no se reemplazan hasta verificar.

B. Si hay 6 distintos tipos de escritura en el campo de estación de origen, normalizo los datos, para darle el mismo formato a los datos del campo.

Momento 3

Jhonatan gutierrez rondon

3.1

a. está en un archivo llamado punto_a.ipynh

b. la diferencia está en que la media es sensible a valores grandes como los viajes largos, para el gerente le sirve más la mediana 18.00 porque es la menos afectada

c. no respondí :(

3. 2

a. la columna edad_usuarios no es una columna es una fila pero bueno, los datos nulos si son sistemáticos cualquier analisis que tenga que ver con la edad estará también sesgado entonces pueden ser aleatorios

b. la hipótesis de de la distribución es que se presentan más viajes en esa franja horaria porque son los horarios que coinciden con la mayoría de horas de ingreso a universidades, trabajos, colegios y lo mismo a la hora de la salida.

hallazgo 1

evidencia (cirfa) = 0 %

riesgo o pregunta que abre = dice que son 0% de costos ed en todos los años de esos viajes no hubo robo de vehículos y daños

Momento 4

Momento 4 · La reunión caótica

17 minutos | Corredor 4 | 25 puntos | Insumo: M4_transcripcion_kickoff.csv (Anexo C)

Te tocó ser el único de tu equipo en la reunión de kickoff. Nadie tomó acta ordenada. Solo quedó la transcripción. Con eso hay que arrancar el sprint.

4.1 Mapa de actores · 6 puntos

Clasifica a todos los actores que aparecen en la transcripción:

Actor	¿Stakeholder, usuario final o ambos?	Interés principal	Influencia
Marcela	Gerente General	Rapidez y estabilidad del sistema	Alta
Julian	Coordinador de Operaciones	Mejorar orden del sistema y inventario	Medio
Daniel	App	Mejorar Manejo de datos	Medio
Andrés	Desarrollador backend	Usar la Plataforma	Baja
Area Jurídica	Area Jurídica	Mundo GD país le es familiar. Protección de Datos para evitar problemas legales.	Medio

Además: identifica al actor que fue mencionado pero no estuvo en la reunión y explica qué riesgo genera esa ausencia.

4.2 Extracción de requerimientos · 8 puntos

- Mínimo 4 requerimientos funcionales, redactados como «El sistema debe permitir...».
- Mínimo 3 requerimientos no funcionales, indicando la categoría: rendimiento, seguridad, usabilidad, disponibilidad o escalabilidad.
- Una frase de la transcripción que NO es un requerimiento — una queja, un deseo vago o una solución impuesta — reescrita como requerimiento verificable.

4.3 Historias de usuario · 11 puntos

Redacta tres historias de usuario, cada una para un rol distinto, en este formato:

Estructura	Contenido
Como <rol> quiero <acción> para <beneficio de negocio>	
Criterios de aceptación (Gherkin): Dado... / Cuando... / Entonces...	
Prioridad MoSCoW y justificación en una línea	


- Cada historia debe tener mínimo dos criterios de aceptación.
- Una de las tres debe ser una historia técnica del equipo de datos, no de la app.

Entregable: mapa de actores, lista de requerimientos funcionales y no funcionales, y tres historias.


El excel está en el repositorio de Juan Camacho

Momento 5

5.1



5.2



5.3

Primera pregunta; la diferencia se presenta en dos cosas en que el diagrama de la izquierda es más técnico y específico dado que debemos incluir que tipos de datos son, si

son públicos o privados, el porque no son el mismo diagrama es debido a que el de la izquierda se usa para dar forma a la parte técnica a la base de datos y el de la izquierda es el que da forma a toda la parte lógica para que los diseñadores de la base de datos se puedan crear.

Segunda pregunta; la relación entre las clase de la cual se relaciona con cual, dado que lo pude haber relacionado de mejor manera entre las clase.

Tercera pregunta; estos modelos se aterrizan en la fase de diseño de la base datos, porque a partir de ellos damos forma a las base de datos.

Hoja de Ruta

Anexo D · Hoja de Ruta del grupo

Este es el pasaporte del equipo. Sin sello no hay avance. Sin la firma de los cinco corredores no se recibe la cartulina.

Firma consultora (nombre del grupo): J J J A

Hora de inicio: 1:25 Pm Hora de finalización: 4:08 Pm Tiempo total: 2:43

Momento	Corredor titular	Hora de entrega	Checkpoint	Sello	Penalización
1. Sala de servidores	Juan Felipe Cordero	1:54 p.m			
2. Datos sucios	Amelia Taya T.	3:42 p.m			
3. El tablero miente	Jhonatan Guitierrez	3:32 p.m			
4. La reunión caótica	Juan Felipe Cordero	4:08 p.m			
5. El muro	Jorge Silvio Rega	3:37 p.m			-0.5

Firmas de los cinco corredores:

1	2	3	4	5
Juan Felipe Cordero	Amelia Taya T.	Jhonatan Guitierrez	Juan Felipe Cordero	Jorge Silvio Rega